

人形机器人强化学习中的奖励与惩罚函数综合分析

引言

人形机器人是人工智能与控制系统领域的巅峰挑战之一，其高维、动态不稳定的特性要求控制策略能够在复杂的物理约束下完成行走、跑动、维持平衡和操作物体等任务¹。在众多控制方法中，强化学习(RL)通过试错交互的方式，使智能体能够自主学习最优行为策略，展现出巨大的潜力²。然而，强化学习的成功在很大程度上取决于一个核心要素：奖励函数的设计。

奖励函数是智能体学习的唯一导向信号，它将高层次的任务目标(例如，“向前行走”)转化为一个可量化的数学标量，从而引导智能体的行为探索²。对于人形机器人而言，奖励函数的设计尤为复杂和关键。它不仅需要定义任务的最终成功，还必须在每一步都提供细致的反馈，以塑造其行为的方方面面：从基本的姿态稳定、步态的自然性与能效，到操作的精确性，乃至硬件的自我保护。一个精心设计的奖励与惩罚系统，是平衡任务完成度、稳定性、效率和安全性这多个矛盾目标的根本工具。

然而，设计有效的奖励函数本身就是一个巨大的瓶颈，通常需要大量的领域知识、手动工程和反复迭代优化¹。这种挑战催生了奖励函数设计方法的不断演进。最初，研究人员依赖于手动工程，通过组合多个加权项来构建复杂的奖励结构。随后，为了解决手动设计的局限性，研究领域转向了从人类数据中学习奖励的范式，例如逆向强化学习(IRL)和基于人类反馈的强化学习(RLHF)。近年来，随着大型语言模型(LLM)的兴起，自动化的奖励函数生成与优化框架也开始出现，预示着人形机器人行为编程方式的深刻变革。

本报告旨在对人形机器人训练中常用的奖励与惩罚函数进行一次全面、深入的分析。报告将从奖励设计的基础原则出发，系统性地梳理用于实现核心运动与稳定性的奖励组件，探讨面向高级操作与动态任务的特定奖励结构，并归纳保障机器人安全的常用惩罚机制。最后，报告将审视从人类数据中学习和自动化生成奖励的前沿范式，并为实践者提供一个决策框架与未来展望。

1. 奖励函数设计的基础原则

在深入探讨具体的奖励函数之前，有必要首先理解其背后的核心设计理念、方法学以及普遍存在的挑战。这些基础原则构成了所有机器人奖励设计工作的理论基石。

1.1. 核心方法学：奖励工程与奖励塑造

奖励函数的设计过程可以分为两个主要领域：奖励工程 (Reward Engineering) 和奖励塑造 (Reward Shaping)²。

奖励工程 指的是奖励函数的初始创建过程。它涉及将一个抽象的任务目标转化为一个具体的数学函数 $R(s,a,s')$ ，该函数将状态 s 、动作 a 和后继状态 s' 映射到一个奖励值²。这个过程是强化学习应用于现实世界的关键瓶颈，因为它要求设计者具备深厚的领域知识，能够预见并编码所有期望的行为特征和不期望的行为后果¹。一个好的工程化奖励函数应在信息量和稀疏度之间取得平衡：既要提供足够密集的信号以加速学习，又要避免过于具体而导致智能体找到“捷径”或“破解” (hacking) 奖励，从而产生非预期的行为²。

奖励塑造 则是在初始奖励函数建立之后，对其进行修改以提供额外的、更密集的引导信号，目的是在不改变任务最优策略的前提下加速学习收敛²。最著名且理论上最完善的方法是

基于势能的奖励塑造 (Potential-Based Reward Shaping, PBRs)。该方法通过引入一个势函数 $\Phi(s)$ 来修改原始奖励 R ，新的奖励函数 R' 定义为：

$$R'(s,a,s')=R(s,a,s')+\gamma\Phi(s')-\Phi(s)$$

其中 γ 是折扣因子。PBRs 的核心优势在于它保证了智能体学习到的最优策略与仅使用原始奖励 R 时完全相同²。然而，尽管PBRs提供了坚实的理论保障，但如何设计一个能有效引导学习的势函数

$\Phi(s)$ 本身就是一个不小的挑战⁴。

这种从奖励工程到奖励塑造的流程，揭示了奖励设计的一个演化路径。实践者首先通过工程手段定义“做什么”(任务目标)，然后通过塑造技术优化“如何学”(学习过程)。随着任务复杂度的增加，这种流程逐渐演变为一个更加动态和自动化的过程，例如通过元学习自动调整奖励权重，这标志着奖励设计正从静态的手动配置向动态的自适应系统演进。

1.2. 稀疏奖励挑战与密集化策略

奖励信号的密度是影响学习效率的关键因素。

稀疏奖励 指的是智能体只有在完成任务的最终时刻才能获得非零奖励(例如, 到达目标点时获得+1奖励, 其余时间为0)。这种奖励函数定义简单, 且不易被智能体“破解”⁷。然而, 在长时程、高维度的任务(如人形机器人导航)中, 稀疏奖励使得探索和信用分配变得极其困难, 智能体可能在无数次失败的尝试中都无法偶然发现获得奖励的路径, 从而导致学习停滞⁷。

密集奖励 则是在每个时间步都为智能体提供反馈(例如, 奖励值与到目标的距离成反比)。这能显著加速学习过程, 但其设计也充满陷阱。设计不当的密集奖励很容易引入非预期的局部最优解。例如, 一个简单的“距离目标越近奖励越高”的函数, 可能会让机器人卡在无法绕过的障碍物前, 因为它无法接受暂时远离目标以寻找通路所带来的短期惩罚⁷。

为了应对稀疏奖励任务的挑战, 研究人员开发了多种先进技术。例如, 自平衡塑造奖励(Self-Balancing Shaped Rewards)通过同时采样两条“兄弟轨迹”(sibling trajectories), 并将其中一条轨迹的终点作为另一条轨迹的“反目标”(anti-goal), 从而产生一个既鼓励接近目标又主动逃离局部最优区域的动态奖励信号⁷。另一种方法是

自监督在线奖励塑造(Self-supervised Online Reward Shaping, SORS), 它利用原始的稀疏奖励信号对智能体生成的轨迹进行排序, 然后基于这个排序结果学习一个密集的奖励函数, 从而自动地将稀疏信号转化为有效的密集引导⁸。

1.3. 多目标奖励的组合与加权

绝大多数复杂的人形机器人任务都是多目标的, 需要在完成主要任务的同时, 满足一系列辅助约束, 如保持平衡、节约能源、避免碰撞等⁴。因此, 最终的奖励函数通常是多个奖励分量的加权和¹⁰。

然而, 如何设定这些分量的权重是一个核心难题。权重的选择对最终学到的行为有着决定性影响。手动调整这些权重是一个极其耗时、依赖直觉和反复试错的过程, 并且很容易陷入由人类偏见导致的次优解, 或者过度拟合于训练的某个特定阶段¹。

为了解决这个“加权困境”, 动态权重自适应框架应运而生。**奖励训练轮(Reward Training Wheels, RTW)**是一个典型的例子, 它采用了一种“教师-学生”模型⁴。在这个框架中, “学生”(机器人智能体)的学习奖励由主要任务奖励和多个加权的辅助奖励构成。“教师”智能体则负责监控学生的学习状态——例如任务成功率、各个辅助奖励项的得分历史等——并动态调整辅助奖励的权重¹²。这个过程类似于教孩子学骑自行车: 初期给予较强的辅助(高权重的“训练轮”奖励), 随着学生能力的提升, 逐渐降低辅助权重, 最终让其独立完成任务。这种方法将繁琐的手动调参过程自动化, 使奖励系统能够智能地适应智能体的学习进程。

在实践中, 理论的完备性与经验的有效性之间常常存在一种微妙的张力。例如, PBRs虽然提供了

最优策略不变性的理论保证,但在某些复杂的实际应用中,它可能会因为引入额外的计算或改变价值函数的景观而实际损害学习性能,甚至增加策略梯度更新的方差¹⁴。这使得实践者有时不得不在理论的“纯洁性”和经验的“有效性”之间做出权衡,甚至会有意采用非基于势能的奖励塑造方法,尽管这可能改变最优策略,但却能在可接受的计算成本内更快地收敛到一个“足够好”的策略。

2. 人形机器人运动与稳定性的核心奖励函数

本节将详细介绍构成大多数人形机器人运动策略基础的具体奖励函数组件。这些组件共同定义了机器人的核心能力,如行走、平衡和高效运动。

2.1. 任务导向奖励(主要目标)

这类奖励直接关联于机器人需要完成的核心任务。

- **速度跟踪**:这是最常见的运动任务目标。奖励函数通常被设计为机器人当前速度与指令速度向量 $(v_{xcmd}, v_{ycmd}, \omega_{zcmd})$ 之间误差的指数函数。其数学形式通常为 $\exp(-error^2/\sigma)$, 其中 $error$ 是指令速度与实际速度之间的平方差,例如 $(v_{xcmd}-v_x)^2$ ¹⁰。这种形式的奖励鼓励机器人精确地跟踪前进、侧向和转向的指令速度。
- **目标到达**:在导航任务中,奖励用于激励机器人最小化其与目标点之间的距离。这可以是一个基于欧氏距离的密集奖励,也可以是在机器人成功到达目标区域时给予的一个稀疏奖励¹⁵。
- **航向保持**:与速度跟踪类似,该奖励项激励机器人将其身体朝向与目标方向对齐,这对于定向行走至关重要。

2.2. 稳定性与平衡奖励(生存与姿态)

这类奖励是确保机器人能够持续运行而不摔倒的基础。

- **生存奖励**:在机器人没有摔倒的每个时间步,给予一个小的、恒定的正奖励。这个简单的奖励项激励智能体尽可能地延长回合(episode)的持续时间,从而间接学会避免导致任务失败的行为¹⁰。
- **躯干高度**:惩罚机器人躯干的实际高度 h 与期望高度 h_{des} 之间的偏差。其形式通常为 $-(h_{des}-h)^2$ ¹⁰。这个奖励项可以有效防止机器人蹲下、弯曲或瘫倒。

- 躯干姿态:惩罚躯干或骨盆相对于垂直轴的倾斜。这是维持平衡的关键。其数学形式通常为 $- \| \text{gproj_xy} \| / 2$, 其中 gproj_xy 是重力向量在机器人局部水平面(xy平面)上的投影¹⁰。当机器人直立时, 这个投影向量的模长接近于零。
- 质心(CoM)稳定性:更直接地衡量动态稳定性的方法是奖励机器人的质心保持在其足部的支撑多边形内。这比单纯的躯干姿态奖励更能反映机器人的动态平衡状态。

2.3. 步态与运动风格奖励(自然性与效率)

这类奖励旨在使机器人的运动不仅有效, 而且看起来自然、平滑且节能。

- 能量最小化:这是生成类人自然步态的关键组成部分。生物力学研究表明, 动物在不同速度下会本能地选择最节能的步态¹⁷。在机器人中模拟这一原则可以涌现出自然的运动模式。
 - 功率消耗惩罚:通常被建模为所有关节瞬时功率的负值, 即 $-\sum \max(\tau \cdot \dot{q}, 0)$, 其中 τ 是关节力矩, $\dot{q}$ 是关节角速度。这惩罚了电机所做的正功, 直接与能量消耗相关¹⁰。
 - 力矩惩罚:一个简单的 $- \| \tau \| / 2$ 项可以有效抑制过大的关节力矩, 这不仅能减少能量消耗, 还能降低对电机和机械结构的磨损¹⁰。
- 步态对称性与周期性:为了鼓励对称和有节奏的步态, 可以设计奖励项来惩罚左、右腿对应关节角度的差异¹⁸。另一种更复杂的方法是使用基于时钟的信号, 在步态周期的特定阶段(如支撑相或摆动相)给予奖励, 从而强制形成周期性运动¹⁹。
- 平滑度:为了避免机器人产生急动、震颤的动作, 通常会引入平滑度惩罚。这可以通过惩罚较大的关节角加速度($- \| \ddot{q} \| / 2$)或连续两个时间步之间动作的变化率($- \| \dot{a}_t - \dot{a}_{t-1} \| / 2$, 也称为“动作率”惩罚)来实现¹⁰。

2.4. 表1: 人形机器人运动常用奖励组件汇总

下表总结了在人形机器人运动任务中最常用的一些奖励和惩罚组件, 为实践者提供了一个快速参考指南, 将抽象的概念与具体的数学实现联系起来。

组件	目的	数学形式 / 概念	示例权重	来源
生存奖励 (Survival)	鼓励回合持续, 避免摔倒	+c (恒定的正奖励)	+0.025	¹⁰

速度跟踪 (X) (Velocity Tracking)	匹配指令前进速度	$\exp(-(v_{xcmd}-v_x)^2/\sigma_x)$	+1.0	10
躯干高度 (Base Height)	保持直立姿态, 防止蹲下	$-(h_{des}-h)^2$	-20.0	10
躯干姿态 (Orientation)	保持躯干垂直于地面	$- \text{gproj_xy} $	-5.0	10
功率消耗 (Power Consumption)	最小化能量消耗, 促进自然步态	$-\sum \max(\tau \cdot \dot{q}, 0)$	-2e-4	10
关节力矩 (Torque)	减少电机负载和能耗	$- \tau $	-2e-4	10
关节角加速度 (Joint Acceleration)	促进运动平滑, 避免急动	$- \ddot{q} $	-1e-7	10
动作率 (Action Rate)	促进控制信号平滑	$- \dot{a}-\dot{a}_{t-1} $	-1.0	10
足部打滑 (Feet Slip)	确保支撑脚稳定接触地面	$-1_{stance} \cdot v_{feet} $	-0.1	10

3. 面向高级与特定任务的奖励函数

当任务从持续的运动(如行走)转变为具有明确阶段和目标的复杂操作时, 奖励函数的设计也必须相应地变得更加结构化和精细。

3.1. 操作任务(到达与抓取)

机器人抓取是一个典型的多阶段序列任务，其奖励函数必须能引导智能体按顺序完成“到达-抓取-提升/放置”等一系列子任务。

- 多阶段奖励结构：由于任务的序列性，一个单一的、扁平的奖励函数往往难以奏效。因此，抓取任务的奖励函数通常被设计为分阶段的结构。
- 到达阶段：在这一阶段，主要目标是引导机械臂的末端执行器（手爪）接近目标物体。一个密集的、基于欧氏距离的奖励项，如 $-||\text{pgripper}-\text{pobject}||/2$ ，被广泛用于此目的，它能为智能体提供清晰的梯度以靠近目标¹⁶。
- 抓取成功：当机器人成功稳定地抓住物体时，会给予一个较大的离散正奖励。抓取成功的判断标准可以多样化，例如基于手部的接触传感器或力传感器读数，或者简单地检测物体是否被成功抬离其初始位置¹⁶。
- 抓后姿态：在许多应用中，仅仅抓住物体是不够的，还需要以特定的姿态或方向持有物体。因此，可以在抓取成功后，再额外给予一个奖励，以鼓励机器人将物体调整到期望的最终位姿¹⁶。这对于将物体精确放置到货架或进行装配等任务至关重要。

3.2. 动态与复杂机动（如站起）

像从摔倒状态站起这样的动态复杂任务，对奖励函数的设计提出了更高的要求。这类任务涉及多个逻辑上和物理上截然不同的阶段（例如，调整躯干姿态、用手臂支撑地面、收腿、最终起身），并且在整个过程中接触状态是动态变化的²¹。

- 任务挑战：用一个单一的加权和奖励函数来覆盖所有这些阶段是非常困难的，因为不同阶段的子目标可能是相互冲突的。例如，在用手臂支撑的阶段，躯干可能是倾斜的，这会与常规的“保持躯干直立”奖励项相矛盾。
- 多评价器架构 (Multi-Critic Architectures)：为了解决这一挑战，像HoST (Humanoid Standing-up Control) 这样的先进框架采用了多评价器架构²⁰。在这种架构中，整个任务的奖励被分解为多个独立的奖励组，每个奖励组对应任务的一个特定阶段或一个特定的子目标。系统会为每个奖励组训练一个独立的评价器 (Critic)，从而允许智能体独立地优化每个子目标，而不会因为不同奖励项之间的冲突而干扰学习过程。这使得智能体能够更好地学习和平衡不同阶段的复杂技能。
- 课程学习 (Curriculum Learning)：为了进一步降低学习难度，这类任务的训练通常与课程学习相结合。训练可以从一个相对容易的初始姿态开始（例如，俯卧），然后逐步过渡到更具挑战性的姿态（例如，侧卧或仰卧）。在训练初期，还可以引入一些辅助手段，如在仿真环境中施加一个虚拟的“向上的拉力”，以帮助智能体更容易地探索到站起的动作序列²⁰。

从这些例子中可以观察到一个普遍的模式：奖励函数的结构直接反映了任务的内在复杂性。对于行走这种单一、连续的任务，一个扁平的、由多个分量加权求和构成的奖励函数是适用的。然而，对于像抓取和站起这样具有明确逻辑和时间顺序的、可分解的复杂任务，奖励函数本身也必须变得更加结构化和模块化。它从一个简单的“和”演变为一个更复杂的“架构”，例如隐式的状态机（先抓取，再放置）或显式的多评价器系统。这一观察为实践者提供了一个重要的设计启发：在设计奖

励函数之前，首先应深入分析任务的内在结构，然后构建一个能够与之匹配的奖励架构。

4. 常用惩罚函数与终止条件

在强化学习中，定义失败并阻止不期望的行为与鼓励成功同等重要。惩罚函数（即负奖励）和终止条件是实现这一目标的主要工具，它们共同构成了机器人的“安全网”。

4.1. 安全性与硬件保护

这些惩罚旨在防止机器人因执行危险动作而对自身造成物理损伤。

- 关节限位：当任何一个关节的角度 q 超出其在物理上或软件上设定的最小/最大范围 $[q_{min}, q_{max}]$ 时，必须给予一个巨大的惩罚，或者直接终止当前回合¹⁰。这是保护机器人关节和连杆免受机械损伤的最基本、也是最重要的约束。
- 力矩限位：持续的高力矩输出会使电机过热甚至烧毁。因此，需要对接近或超过电机额定最大力矩 τ_{max} 的行为进行惩罚²²。一种常见的形式是引入一个与力矩使用率相关的惩罚项，如
$$- // \tau / \tau_{max} // 2$$
（在某些文献中被称为“力矩疲劳”惩罚）¹⁰。
- 自碰撞：当机器人的不同身体部位（如手臂与躯干）发生碰撞时，应给予严厉的惩罚或终止回合²²。自碰撞的检测通常依赖于机器人的几何模型和持续的距离检查，这在计算上可能非常昂贵。为了提高效率，一些先进方法会预先学习一个“边界函数”，该函数可以在关节空间中高效、可微地近似自碰撞区域，从而可以轻松地集成到基于优化的控制器中²³。

4.2. 稳定性与任务失败（终止条件）

这些条件定义了任务的失败，并为智能体提供了最强烈的负面学习信号。

- 摔倒检测：摔倒是最常见的任务失败形式。通常通过以下一个或多个条件来触发：
 - 机器人的基座（通常是骨盆或躯干）高度低于某个预设的最小阈值¹⁰。
 - 基座的俯仰角或翻滚角超过了一个安全范围，表明机器人失去了平衡²⁴。
 - 除了脚部以外的任何身体部位（如膝盖、手、躯干）与地面发生接触。
- 回合终止：一旦检测到摔倒或其他严重故障（如自碰撞），当前训练回合将立即被终止。通常，在终止时会给予智能体一个较大的负奖励。这种“死亡惩罚”为智能体提供了明确的信号，使

其学会不惜一切代价避免进入导致失败的状态。

4.3. 运动正则化惩罚

这些惩罚项旨在规范机器人的运动方式，使其更加平滑、稳定和可控，即使这些动作本身并未直接导致任务失败。

- 过大的速度:对z轴方向(垂直方向)的线速度($-v_z^2$)或翻滚/俯仰方向的角速度($-\|\omega_{xy}\|^2$)进行惩罚，可以有效抑制机器人不必要的跳跃、摇晃或摆动¹⁰。
- 过大的关节速度:对所有关节速度的范数($-\|\dot{q}\|^2$)进行惩罚，可以鼓励机器人以更平滑、更可控的方式运动，避免过快的关节转动¹⁰。
- 足部打滑:当机器人的某只脚处于支撑相(即应该稳定地踩在地面上)时，任何检测到的水平方向滑动都应受到惩罚。这通常通过 $-1_{\text{stance}} \cdot \|v_{\text{feet}}\|^2$ 来实现，其中 1_{stance} 是一个指示函数，表示该脚是否处于支撑相¹⁰。这个惩罚对于实现稳定的行走至关重要。

4.4. 表2: 常用惩罚函数与终止触发器汇总

下表为实践者总结了在人形机器人训练中用于定义失败、保障安全和规范行为的关键惩罚项与终止条件。

组件 / 触发器	目的	形式 / 概念	类型	来源
摔倒 (Fall)	因失衡终止回合	基座高度 < $h_{\min}$ 或 基座姿态 > $\theta_{\max}$ 或非足部接触	终止	24
关节位置限位 (Joint Position Limit)	防止机械损伤	if $q > q_{\max}$ or $q < q_{\min}$	惩罚/终止	10
力矩限位 (Torque Limit)	防止电机过载	$-\ \tau/\tau_{\max}\ ^2$	惩罚	10

自碰撞 (Self-Collision)	防止自我损伤	if 连杆间距 < dmin	惩罚/终止	22
关节速度 (Joint Velocity)	鼓励平滑运动	$- \ \dot{q} \ ^2$	惩罚	10
基座Z轴速度 (Base Z-Velocity)	抑制跳跃/震荡	$-v_z^2$	惩罚	10
足部打滑 (Foot Slip)	维持稳定立足点	$-1_{\text{stance}} \cdot \ v_{\text{feet}} \ ^2$	惩罚	10

5. 奖励设计的前沿范式

随着人形机器人任务的日益复杂，传统的手动奖励工程变得越来越不切实际。为此，研究界开发了一系列先进的范式，旨在从数据和高级指令中自动学习或生成奖励函数，从而将设计的重点从“如何编码行为”转向“如何传达意图”。

5.1. 从人类数据中学习奖励

这类方法的核心思想是利用人类的直观判断和行为示范来代替繁琐的数学公式。

- **逆向强化学习 (Inverse Reinforcement Learning, IRL)**: 与给定奖励函数学习最优策略的正向RL不同, IRL试图从专家(通常是人类)的行为演示中反向推断出其内在的奖励函数¹⁸。其基本假设是, 专家的演示行为是在其未知的奖励函数下的最优(或近最优)策略。通过找到一个能最好地解释专家行为的奖励函数, 机器人就可以利用这个学到的奖励函数来训练自己的策略。IRL在从运动捕捉(MoCap)数据中学习自然的、类人的运动方面非常强大⁹。
 - **形态差异挑战**: 一个主要障碍是, 由于自由度、关节限位和动力学特性的差异, 人类的MoCap数据对机器人来说往往是物理上不可行的²⁷。
 - **双层优化解决方案**: 为了解决这个问题, 像**双层运动模仿(Bi-Level Motion Imitation, BMI)**这样的框架被提出来。BMI采用一种双层优化策略, 它不仅优化机器人的策略以更好地模仿参考数据, 同时还反过来优化参考的MoCap数据, 使其在物理上对机器人更

加可行和一致, 从而弥合人与机器人之间的形态鸿沟²⁷。

- **基于人类反馈的强化学习 (Reinforcement Learning from Human Feedback, RLHF):** RLHF进一步降低了对人类专家的要求, 它不再需要完整的行为演示。取而代之的是, 系统会向人类标注员展示两段或多段机器人执行任务的轨迹片段, 并询问他们更偏好哪一个³¹。这些成对的偏好数据被用来训练一个独立的“奖励模型”, 该模型的目标是学习预测人类的偏好。一旦奖励模型训练完成, RL智能体就会被训练来最大化从这个模型中获得的奖励³¹。RLHF对于那些难以用数学公式精确定义, 但人类却能轻易判断好坏的任务(例如, “以一种安全自然的方式行走”)尤其有效³¹。

5.2. 利用大型语言模型(LLM)自动生成奖励

最近的研究开始探索利用大型语言模型(LLM)强大的推理和代码生成能力, 来自动化整个奖励工程过程¹。

- **核心理念:** 将奖励设计问题转化为一个语言任务。人类用户只需用自然语言描述任务目标(例如, “让机器人在不平坦的地面上冲刺”)。
- **STRIDE等框架:** 在像STRIDE这样的框架中, LLM接收自然语言形式的任务描述以及机器人的技术规格文件(如URDF)。基于这些信息, LLM会自动生成可执行的Python代码, 作为该任务的奖励函数¹。
- **迭代优化循环:** 生成的奖励函数被用于短暂地训练一个RL策略。然后, 将训练过程中的性能指标(如速度、稳定性、能耗)以文本形式反馈给LLM。LLM会“反思”这些反馈, 并对奖励函数的代码进行“变异”——调整权重、修改奖励项, 甚至添加新的组件——以期在下一轮迭代中获得更好的性能¹。这个闭环过程将原本需要人类专家数周才能完成的繁琐调优工作, 自动化地在数小时内完成。

从手动工程到IRL/RLHF, 再到LLM, 这一演进轨迹清晰地展示了人机交互范式的深刻转变。最初, 我们必须通过精确的数学语言来指定期望的行为。随后, 通过IRL和RLHF, 我们开始通过更直观的方式——示例(演示)和比较(偏好)——来沟通我们的意图。如今, 借助LLM, 我们正迈向用自然语言直接表达意图的时代。这一进程显著降低了机器人编程的门槛, 并直接解决了机器人领域的一个核心难题: 人类通常知道自己想要什么, 但很难将其严格地形式化³²。

然而, 随着奖励设计过程的自动化程度越来越高, 核心挑战也从“如何让智能体学得更快”转变为“如何确保学到的/生成的奖励函数真正符合我们的意图”。这就是所谓的“对齐”(Alignment)问题。一个对LLM的模糊指令, 或是在RLHF中带有偏见的人类反馈, 都可能导致机器人完美地优化一个我们不希望看到甚至危险的行为³¹。例如, 一个旨在“移动桌上木块”的简单奖励函数, 可能导致机器人学会掀翻整张桌子, 因为它找到了一个获得更高奖励的“捷径”。因此, 随着奖励设计能力的增强, 如何验证奖励模型的有效性、如何处理带噪声的人类输入, 以及如何确保最终行为符合高层次的安全和伦理原则, 正成为日益重要的研究方向。

6. 综合、实践建议与未来展望

本报告系统地梳理了人形机器人强化学习中奖励与惩罚函数的设计原则、核心组件和前沿范式。本节将对所有内容进行综合，为实践者提供一个决策框架，并探讨该领域面临的开放挑战与未来发展方向。

6.1. 实践者指南：一个奖励设计的决策框架

对于一个刚接触新任务的机器人研究者或工程师，以下决策流程可以作为一个起点，系统地构建和迭代奖励函数：

1. 任务分析：首先，深入理解任务的性质。
 - 这是一个连续的、单一目标的任务（如匀速行走），还是一个分阶段的、序列化的任务（如抓取并放置）？
 - 任务的成功是否有明确、可量化的指标（如到达时间、放置精度）？
2. 选择基础方法论：根据任务性质选择合适的起点。
 - 手动工程：对于目标明确、物理约束清晰的任务（如运动控制），从手动设计一个加权求和的奖励函数开始是最直接有效的方法。
 - 逆向强化学习 (IRL)：如果你拥有高质量的人类演示数据（如MoCap），并且任务目标是模仿某种“风格”或“自然性”，IRL是一个强有力的选择。
 - 基于人类反馈的强化学习 (RLHF)：对于目标主观、难以量化（如“安全地与人交互”）的任务，RLHF是最佳选择，因为它将判断的负担交给了人类直觉。
3. 选择核心组件：参考本报告中的表1和表2，为你的任务挑选必要的奖励与惩罚“积木”。
 - 基础项：对于任何动态任务，生存奖励、姿态稳定惩罚、关节/力矩限位惩罚都是必不可少的。
 - 任务项：根据你的主要目标添加任务导向奖励（如速度跟踪、距离目标）。
 - 风格项：如果需要，添加运动风格奖励（如能耗最小化、平滑度惩罚）。
4. 从简开始：在初始阶段，避免过度设计。选择3-5个最关键的奖励/惩罚项，并使用简单的、凭经验选择的权重。一个过于复杂的奖励函数在早期会使调试变得异常困难。
5. 迭代与调试：观察智能体在训练中涌现的行为。
 - 它是否在“破解”奖励？（例如，为了获得“前进”奖励而疯狂蹬腿但原地不动）。如果是，说明你的奖励函数存在漏洞，需要添加额外的惩罚项（如惩罚足部打滑）或修改奖励定义。
 - 学习过程是否过于缓慢或不稳定？这可能意味着奖励信号过于稀疏或不同项之间存在冲突。可以尝试增加密集引导信号（奖励塑造）或调整权重。
6. 考虑自动化：当手动调优成为瓶颈时，引入更先进的工具。
 - 如果权重平衡问题持续存在，可以考虑实现类似RTW的动态权重调整机制。

- 如果对如何设计新的奖励项感到困惑，可以尝试使用LLM框架（如STRIDE）来从自然语言描述中获得一些创新的想法或代码草案。

6.2. 开放挑战与未来方向

尽管人形机器人的奖励设计已取得长足进步，但仍有许多悬而未决的问题和激动人心的研究方向。

- 通用奖励函数：我们能否开发出一种“通用”或“基础”的奖励函数，只需少量针对特定任务的修改，就能适用于多种不同的人形机器人平台和广泛的任务类型？这可能需要将物理学第一性原理与从大规模数据中学习到的先验知识相结合。
- 安全与对齐的保证：随着奖励设计过程日益自动化和黑箱化，如何为最终学到的策略提供形式化的安全保证？如何确保一个由LLM生成或由人类偏好训练出的奖励函数，其所引导的行为在所有情况下都与人类的价值观和意图保持一致？这需要开发新的验证、测试和约束优化技术。
- 终身学习与奖励自适应：在机器人的整个生命周期中，其任务目标和所处环境都可能发生变化。如何设计一个能够与机器人共同演化的奖励系统？机器人能否在与世界的持续交互中，自主地发现新的有意义的目标，并相应地更新其内在的“价值体系”？
- 人机交互的未来：从“指定”到“沟通”的范式转变为我们描绘了一个新的未来。在这个未来中，为机器人编程可能不再是一个单向的指令下达过程，而更像是一种人与机器之间的协作对话。人类通过高级语言、演示和反馈来表达意图，而机器则通过学习和交互来理解并完善这些意图，最终共同创造出期望的行为。这将彻底改变机器人技术的可及性和应用范围。

引用的著作

1. STRIDE: Automating Reward Design, Deep Reinforcement Learning Training and Feedback Optimization in Humanoid Robotics Locomotion - arXiv, 访问时间为 九月 30, 2025, <https://arxiv.org/html/2502.04692v1>
2. Comprehensive Overview of Reward Engineering and Shaping in Advancing Reinforcement Learning Applications - arXiv, 访问时间为 九月 30, 2025, <https://arxiv.org/html/2408.10215v1>
3. Reinforcement learning - Wikipedia, 访问时间为 九月 30, 2025, https://en.wikipedia.org/wiki/Reinforcement_learning
4. Reward Training Wheels: Adaptive Auxiliary Rewards for Robotics Reinforcement Learning, 访问时间为 九月 30, 2025, <https://arxiv.org/html/2503.15724v1>
5. Benchmarking Potential Based Rewards for Learning Humanoid Locomotion - ICRA 2023, 访问时间为 九月 30, 2025, <https://www.youtube.com/watch?v=Qvacov9kujQ>
6. Jacob Adamczyk - New Perspectives on Reward Shaping - YouTube, 访问时间为 九月 30, 2025, <https://www.youtube.com/watch?v=70kVz9G2Z-o>
7. Keeping Your Distance: Solving Sparse Reward Tasks Using ... - NIPS, 访问时间为

九月 30, 2025,

<http://papers.neurips.cc/paper/9225-keeping-your-distance-solving-sparse-reward-tasks-using-self-balancing-shaped-rewards.pdf>

8. Self-Supervised Online Reward Shaping in Sparse-Reward Environments, 访问时间为 九月 30, 2025, <https://rudolf.intuitive-robots.net/papers/SORS.pdf>
9. A Motion Capture and Imitation Learning Based Approach to Robot Control - MDPI, 访问时间为 九月 30, 2025, <https://www.mdpi.com/2076-3417/12/14/7186>
10. Booster Gym: An End-to-End Reinforcement Learning Framework for Humanoid Robot Locomotion - arXiv, 访问时间为 九月 30, 2025, <https://arxiv.org/html/2506.15132v1>
11. [2503.15724] Reward Training Wheels: Adaptive Auxiliary Rewards for Robotics Reinforcement Learning - arXiv, 访问时间为 九月 30, 2025, <https://arxiv.org/abs/2503.15724>
12. Reward Training Wheels: Adaptive Auxiliary Rewards for Robotics ..., 访问时间为 九月 30, 2025, <https://cs.gmu.edu/~xiao/papers/rtw.pdf>
13. [Literature Review] Reward Training Wheels: Adaptive Auxiliary Rewards for Robotics Reinforcement Learning - Moonlight, 访问时间为 九月 30, 2025, <https://www.themoonlight.io/en/review/reward-training-wheels-adaptive-auxiliary-rewards-for-robotics-reinforcement-learning>
14. Behavior Alignment via Reward Function Optimization, 访问时间为 九月 30, 2025, <https://people.cs.umass.edu/~pthomas/papers/Gupta2023.pdf>
15. Improving Bipedal Robot Motion via Reinforcement Learning and Tailored Rewards - Engineered Science Publisher, 访问时间为 九月 30, 2025, https://www.espublisher.com/uploads/article_html/engineered-science/10.30919-es1287.htm
16. Deep Reinforcement Learning for Adaptive Robotic Grasping and ..., 访问时间为 九月 30, 2025, <https://www.mdpi.com/1999-5903/17/10/437>
17. Minimizing Energy Consumption Leads to the Emergence of Gaits in ..., 访问时间为 九月 30, 2025, <https://energy-locomotion.github.io/resources/CoRL-Energy-Locomotion.pdf>
18. Adaptive walking speed motion control of Kuavo humanoid robot based on inverse reinforcement learning - ResearchGate, 访问时间为 九月 30, 2025, https://www.researchgate.net/publication/394406405_Adaptive_walking_speed_motion_control_of_Kuavo_humanoid_robot_based_on_inverse_reinforcement_learning
19. Revisiting Reward Design and Evaluation for Robust Humanoid Standing and Walking, 访问时间为 九月 30, 2025, <https://arxiv.org/html/2404.19173v1>
20. Learning Humanoid Standing-up Control across Diverse Postures - arXiv, 访问时间为 九月 30, 2025, <https://arxiv.org/html/2502.08378v1>
21. Learning Humanoid Standing-up Control across Diverse Postures - arXiv, 访问时间为 九月 30, 2025, <https://arxiv.org/pdf/2502.08378?>
22. QP-Based Adaptive-Gains Compliance Control in Humanoid Falls - LORIA, 访问时间为 九月 30, 2025, <https://members.loria.fr/kbouyarmane/fall.pdf>
23. Real-Time Self-Collision Avoidance in Joint Space for Humanoid Robots - Infoscience, 访问时间为 九月 30, 2025,

- https://infoscience.epfl.ch/record/284240/files/Real-Time_Self-Collision_Avoidance_in_Joint_Space_for_Humanoid_Robots.pdf
24. Whole-Body Control Framework for Humanoid Robots with Heavy Limbs: A Model-Based Approach - arXiv, 访问时间为 九月 30, 2025, <https://arxiv.org/html/2506.14278v1>
 25. Analysis of Cost Functions for Reinforcement Learning of Reaching Tasks in Humanoid Robots - MDPI, 访问时间为 九月 30, 2025, <https://www.mdpi.com/2076-3417/14/1/39>
 26. Adaptive walking speed motion control of Kuavo humanoid robot based on inverse reinforcement learning - Emerald Insight, 访问时间为 九月 30, 2025, <https://www.emerald.com/ir/article/doi/10.1108/IR-01-2025-0015/1271502/Adaptive-walking-speed-motion-control-of-Kuavo>
 27. Bi-Level Motion Imitation for Humanoid Robots - Google Sites, 访问时间为 九月 30, 2025, <https://sites.google.com/view/bmi-cori2024/home>
 28. Human-Inspired Video Imitation Learning on Humanoid Model - World Scientific Publishing, 访问时间为 九月 30, 2025, <https://www.worldscientific.com/doi/pdf/10.1142/S1793351X24500028?download=true>
 29. [2410.01968] Bi-Level Motion Imitation for Humanoid Robots - arXiv, 访问时间为 九月 30, 2025, <https://arxiv.org/abs/2410.01968>
 30. Zhao, Yi; Pajarinen, Joni; Muehlebach, Michael Bi-Level Motion ..., 访问时间为 九月 30, 2025, https://research.aalto.fi/files/177477347/Bi-Level_Motion_Imitation_for_Humanoid_Robots.pdf
 31. Reinforcement learning from human feedback - Wikipedia, 访问时间为 九月 30, 2025, https://en.wikipedia.org/wiki/Reinforcement_learning_from_human_feedback
 32. Designing Reward Functions Using Active Preference Learning for Reinforcement Learning in Autonomous Driving Navigation - MDPI, 访问时间为 九月 30, 2025, <https://www.mdpi.com/2076-3417/14/11/4845>
 33. Learning Reward Functions by Integrating Human Demonstrations and Preferences - Robotics, 访问时间为 九月 30, 2025, <https://www.roboticsproceedings.org/rss15/p23.pdf>
 34. [Literature Review] STRIDE: Automating Reward Design, Deep Reinforcement Learning Training and Feedback Optimization in Humanoid Robotics Locomotion - Moonlight, 访问时间为 九月 30, 2025, <https://www.themoonlight.io/en/review/stride-automating-reward-design-deep-reinforcement-learning-training-and-feedback-optimization-in-humanoid-robotics-locomotion>